

基于机器学习的电磁兼容故障诊断综述

彭宇¹, 张莉¹, 梁培²

(1.中国计量大学,理学院,浙江 杭州 310018;

2.中国计量大学,光学与电子科技学院,浙江 杭州 310018)

摘要:随着电子技术的快速发展,对电子设备性能的要求不断提升,确保设备中器件的稳定性变得至关重要。其中,电磁兼容性的评估对于准确判断器件状态具有重要意义。然而,传统的电磁兼容故障诊断方法存在诸多局限性,难以满足现代电子设备的需求。在人工智能技术的推动下,基于机器学习的电磁兼容故障诊断方法受到广泛关注。本文面向电磁兼容故障分类,对目前应用于该领域的传统诊断方法以及基于传统机器学习的支持向量机(SVM)、BP神经网络和基于深度学习的卷积神经网络(CNN)等3类机器学习故障诊断方法深入研究和对比分析,探讨了这些方法的优缺点。最后,对机器学习在电磁兼容故障诊断领域的发展进行了总结和展望,认为该领域具有广阔的应用前景和深入研究的价值。

关键词:电磁兼容; 故障诊断; 机器学习

中图分类号:TN97

文献标识码:A

文章编号:1000-100X(2025)01-0030-07

A Review of Electromagnetic Compatibility Fault Diagnosis Based on Machine Learning

PENG Yu¹, ZHANG Li¹, LIANG Pei²

(1.China Jiliang University, Hangzhou 310018, China)

Abstract: With the rapid development of electronic technology, the demand for improving the performance of electronic devices is constantly increasing, making it crucial to ensure the stability of components in the devices. Among them, the evaluation of electromagnetic compatibility is significant for accurately judging the status of components. However, traditional electromagnetic compatibility fault diagnosis methods have many limitations and are difficult to meet the demands of modern electronic devices. Driven by artificial intelligence technology, electromagnetic compatibility fault diagnosis methods based on machine learning have received widespread attention. This article focuses on electromagnetic compatibility fault classification, conducting a thorough study and comparative analysis of traditional diagnostic methods currently applied in this field, as well as three types of machine learning fault diagnosis methods, support vector machine (SVM), BP neural network based on traditional machine learning, and convolutional neural network (CNN) based on deep learning. The article discusses the advantages and disadvantages of these methods. Finally, the development of machine learning in the field of electromagnetic compatibility fault diagnosis is summarized and prospected, believing that this field has broad application prospects and the value of further research.

Keywords: electromagnetic compatibility; fault diagnosis; machine learning

Foundation Project: Supported by National Natural Science Foundation of China (No.22174133); Science and Technology Plan Project of State Administration for Market Regulation (No.2020MK190)

1 引言

在现代复杂多变的环境中,设备的正常运行面临着越来越高的要求和挑战。在实际的应用过程中,任何设备中器件的异常都可能引起其他器件或整个设备出现故障,甚至更加严重的后果。因

此,实现准确而高效的设备运行状态诊断,对确保设备能稳定、安全的运行至关重要。

器件作为电子设备不可或缺的组成部分,其稳定性会直接影响到整个设备的运行状态^[1]。当设备中的器件不稳定时,易受到外界辐射的干扰发生故障,并且器件自身出现不稳定和异常时,也可能产生较高的电磁辐射量,并且这些过高的辐射会直接影响周围器件或其他设备的稳定运行。因此,工程应用上电磁兼容性在判断器件稳定性方面扮演着至关重要的角色。通过电磁兼容性测试观察设备产生电磁辐射和受到特定电磁干扰

基金项目:国家自然科学基金(22174133);国家市场总局科技计划(2020MK190)

定稿日期:2024-05-08

作者简介:彭宇(1998-),女,硕士研究生,研究方向为电磁兼容故障诊断。

时的表现,来评估设备整体状态,基于电磁兼容数据,即时对设备整体状态进行诊断,找出导致问题的故障器件,即电磁兼容故障诊断,以保证设备内各器件正常工作,不对其他器件产生负面影响,也不会因其他器件或者外部设备的电磁干扰导致故障和性能下降。而在实际的电磁兼容故障诊断过程中,因设备组成复杂、集成度高,很难快速判定故障原因,并且一个故障表象常常由一个或多个故障引起,实现准确的故障诊断并不容易。

对于目前而言,常用故障诊断方法分为3类:基于模型分析的方法、基于信号处理的方法、基于智能的方法^[2]。其中,基于智能的故障诊断方法是指将机器学习理论应用在机器故障诊断中,无需工程师经验,可从数据中自适应学习诊断知识的方法^[3]。机器学习方法作为一种表示学习工具^[4],已经成功应用于机械、电力等领域,实现了故障诊断、状态监控、故障预测和其他变量的预测,成为人工智能应用中开发智能诊断算法的强大工具。

基于机器学习方法的故障诊断的特点是能够处理具有高维和多变量特点的故障数据,并在复杂和动态环境中提取故障数据中的隐藏关系或模式,通过生成模型,将大量的协变量与一些感兴趣的目标变量联系起来。机器学习技术分为传统方法和深度学习方法两种。传统的机器学习方法在解决特征工程较为明确、数据量较小的故障诊断问题有着明显的优势。其网络结构简单,且易解释,可以很好地融合专家经验和领域知识。尽管在处理一些复杂系统或大规模数据时存在一定限制,但在特定场景下,传统机器学习方法仍是一种有效的故障诊断工具。相比于传统的机器学习方法,深度学习方法在特征映射方面具有联合执行特征映射能力,通过多层的神经网络结构,它能够进行故障特征学习和表示学习,自动地从原始的故障数据中学习得到更抽象、更高级的特征表示,而无需人工设置故障特征,避免人工进行特征提取存在的误差,实现准确的预测并提供最佳的解决方案,减少人力和时间。

综上,基于机器学习方法的故障诊断具有诊断自动化和智能化的优点,可以处理极其复杂的故障数据,并且建立鲁棒性高的模型,这些模型经过训练后,无需依赖任何数学建模和专业知识即可做出快速准确的决策。目前,机器学习方法在电磁兼容故障诊断领域的应用已经取得一定的成果。本文主要将机器学习与传统的故障诊断方法进行对比,探讨基于机器学习电磁兼容故障诊断

的优势并介绍对应的研究成果,包括传统诊断方法、传统机器学习中基于SVM的故障诊断方法、基于BP神经网络的故障诊断方法以及深度学习中基于CNN的故障诊断方法。通过对4类方法的分析,探究电磁兼容故障诊断技术研究中仍存在的问题以及发展趋势。

2 电磁兼容故障分类

电磁兼容故障类型繁多,不同的设备出现故障的器件和原因各异,可将不同故障归纳为两种:①因外部因素引起;②因内部因素引起。

外部因素主要是指来自于环境中的电磁干扰,或者其他设备的电磁辐射对设备产生的干扰,使设备或内部器件无法正常工作。例如:大气放电、人体或者是设备带来的静电、宇宙辐射、外部设备产生的电磁辐射干扰等。

内部因素主要是指器件自身的原因,例如:器件自身的老化、材料的变质和变形、生产的错误、不合理的设计等原因导致器件工作出现异常,并向外发射过高电磁波,这些电磁波会以辐射发射、电磁耦合传导的方式向外传播。其中,辐射发射的干扰信号是通过空间进行传播,属于频率较高的信号。其产生的根本原因在于设备中出现电压或信号的波动,进而引发磁场的变化。例如,设备中不合适的逆变器功率开关器件IGBT的快速通断,产生较强脉冲电压和脉冲电流,以及其内部二极管导通时,产生尖峰电压以及关断时尖峰电流,从而产生较强的辐射干扰;交流发电设备中因出现接触不良的情况,产生大量的电火花,从而产生较强的辐射干扰;开关电源的开关管异常产生高频干扰信号,通过电源线形成等效天线向外辐射。电磁耦合传导则是指设备或系统产生的辐射通过导线或者公共电源线互相干扰,其产生的干扰频率一般较低。具体产生的原因是电源线、地线、电缆等载体之间发生耦合来影响其他电路,或者当电流或电压突然发生变化时,通过寄生电容形成通路,产生干扰。例如,操控平台产生的开关瞬态尖峰信号,通过传导干扰导致驱动放大器发生故障。

3 电磁兼容故障诊断方法

目前,对于设备或器件的电磁兼容性故障诊断的方法主要分为两大类:传统故障诊断方法和机器学习故障诊断方法。传统故障诊断方法主要包括人工故障诊断及故障树诊断方法,该方法在企业中应用比较多,是一种常用手段;而另一种机器学习故障诊断方法,是一种新兴高效的诊断手段。

3.1 传统故障诊断方法

对于电磁兼容故障诊断方法,最传统的是依赖于工程师的专业知识和实践经验,对潜在的可能故障进行排查,工程师主要使用的具体方法包括 6 种:干扰三要素假设法、相关普查法、模拟法、替代法、干扰响应推进法和依次排除法。但由于技术进步、信息融合、多功能需求等原因,现在的设备结构复杂、集成度高,各功能和模块之间相互关联耦合,导致电磁兼容故障的定位变得困难。并且对于同一电磁兼容故障现象,可能存在由多个故障引起,对于工程师而言很难快速对多个故障进行定位。因此传统依靠人工的电磁兼容故障诊断方法存在不准确、周期长、效率低等问题,为提高电磁兼容故障诊断效率和准确性,更加先进和智能的方法被提出应用在电磁兼容故障诊断领域。

对于工业问题的解决,故障树分析法是比较常用的一种分析手段,已经广泛地应用于各个工业领域。它是从系统故障状态出发开始推理,通过以图形的方式展示事件之间的结构层次,以布尔代数表示事件之间的逻辑,最终确定故障发生的原因和概率。

文献[5]将故障树分析方法应用于电磁兼容领域,提出了具体的电磁兼容故障诊断流程,但只进行了理论探究。文献[6]基于故障模式分析,提出电磁兼容故障树建树原则,应用下行法得到最小割集,针对最小割集的重要程度,构建了车载器件的诊断方法。文献[7]对故障树分析法中底事件难以确定的问题,提出基于层次分析法的底事件故障概率计算分析方法,并提出了故障树和现场技术结合,从而实现电磁兼容故障诊断。文献[8]基于电磁兼容三要素进行分析建树,并根据电磁兼容测试数据的特点提出包络特征识别匹配算法,通过对包括特征的辨识,来计算最小割集重要度,从而实现在线的显控类器件的故障识别。文献[9]引入动态故障树分析法到电磁兼容诊断方法中,提出动态子树与静态子树相结合的方法,并验证了对温压复合传感器诊断的有效性。

虽然研究证明了故障树分析法对于电磁兼容诊断具有有效性,但是该方法是通过故障结果推算故障因素,还需要建树工程师全面了解设备,且不同人员可能得出不同的建树结果。对于复杂的设备还需要建立庞大的故障树,考虑因素多且计算量大,不同设备类型因其内部结构、器件不同还需要构建不同的故障树,因此故障树诊断方法依然具有一定局限性。

对于电磁兼容故障诊断而言,电磁兼容数据是进行故障诊断最重要的依据,直接反映了器件的性能和状态。但又因电磁兼容数据具有高维、非线性、复杂逻辑关联等特点,仅仅依靠传统的机理分析方法已经不足以充分提取数据中隐含的故障特征、因果逻辑等关系。在这种提供大量数据的创新背景下,使用数据分析方法来提取知识变得显而易见。研究者已经开始对测试数据进行分析,使用现代技术如机器学习等手段分析测试数据,挖掘电磁兼容数据特征与故障的对应关系,揭示测试数据中隐藏的规律。

3.2 机器学习故障诊断方法

3.2.1 基于支持向量机(SVM)的故障诊断方法

SVM 是基于统计学理论的一种二分类模型,其基本模型定义是寻求特征空间中的最大间隔,在解决 EMC 故障诊断应用中有很强的泛化能力来支持实现精确分类。

如图 1 所示, $w \cdot x + b$ 即为分离超平面,其中在高维空间中最大间隔分离平面唯一存在;基于在特征空间中的训练数据集,选择合适的核函数与惩罚函数,构造凸二次规划问题进行求解,计算超平面的法向量 w 与位移项 b ,通过求解超平面得到分类问题的决策函数,最终实现 SVM 算法。




图 1 SVM 示意图

Fig. 1 Schematic diagram of SVM

对于电磁兼容数据而言,通常包含丰富的特征,例如幅值大小、频率范围、数据类型(谐波、尖峰、包络)以及测试类别等,展现出典型的高维数据特性。SVM 的一个重要扩展:核技巧,正是处理这类高维数据的有效手段。文献[10]通过数据驱动的方式构建 4 层概念模型实现实时的故障诊断,包括:数据准备、测试数据处理和检测数据特征、数据建模以及获得诊断结果。该方法对数据建模模块进行深入研究,将 SVM 和决策树等方法进行对比,最后通过实验验证基于 SVM 的智能系统进行电磁兼容故障诊断对故障进行定位的优势和可行性。文献[11]提出将工作状态中的设备检测获取电磁发射频谱,与 SVM 结合进行电磁发射分析。该方法的数据类别主要是对设备检测产生的

不同电磁发射频谱(谐波干扰、窄带干扰和宽带干扰)提取相应参数,进行 SVM 的类别分类,通过实验验证了该方法的可行性,并提出该方法可用于指导设备的电磁兼容性设计和解决问题的过程。文献[12]介绍了用于电网电磁干扰的各种人工智能技术,其中故障诊断是 SVM 的主要应用之一,它通过对信号中提取的特征对电网中故障器件的位置和类型进行识别。表 1 为 SVM 用于电磁兼容故障诊断。

表 1 SVM 用于故障诊断

Table 1 The application of SVM in fault diagnosis

支持向量机方法	特点
文献[10-12]SVM	可以区分不易区分的故障,有较好的诊断能力
文献[13]DB-TSVM 算法	半监督学习减少无标签样本对模型的影响,使故障分类具有较高准确率

SVM 具有的核函数能够将原始的低维空间数据映射到高维特征空间,使原本线性不可分的数据在高维空间中变得线性可分,并且其目标是在特征空间中找到一个最优的超平面,该超平面能够最大化分类边界,从而确保分类的准确性和稳定性,能够充分利用有限的样本信息,实现小样本分类的目标。对于小样本下电磁兼容数据,SVM 表现很好。文献[13]提出一种基于已有测试数据的电磁兼容反向诊断模型。该方法通过对不同器件故障对应的电磁兼容数据进行特征提取,构建特征和故障类别之间的真值表,实现基于 SVM 方法的电磁兼容故障诊断分类和故障排查,同时还证明使用 SVM 优于朴素贝叶斯方法。文献[14]提出一种密度聚类与 TSVM 半监督支持向量机相结合的电磁兼容诊断方法。该方法是基于电磁兼容特征数据生成无标记样本进行数据增强,并利用半监督聚类算法找出无标签数据隐藏的分布信息,筛选出分类较高的送入 TSVM 进行局部迭代,剩下的进行下一轮迭代,最终实现电磁兼容故障定位。

虽然 SVM 改变了传统电磁兼容诊断的方式,但它属于浅层的学习模型,学习能力有限,更适合小样本数据集。并且 SVM 对特征工程要求高,需要手动地进行电磁兼容数据的特征提取,来挖掘与故障相关的特征,而这非常依赖于该领域的专业知识和经验。对于未来基于 SVM 的电磁兼容故障诊断,可考虑将 SVM 与小波变换、主成分分析、深度学习等方法结合起来进行特征提取和降维,从而避免人工带来的偏差,提高模型的诊断能力。

3.2.2 基于 BP 神经网络的故障诊断方法

BP 神经网络是一种多层前馈监督人工神经网络,其结构主要包括 3 层:输入层、隐含层和输出层,其结构如图 2 所示。BP 神经网络中相邻层之间的神经元可以进行信息传递,而每一层中的纵向神经元间则无信息交互,因此,BP 神经网络可以挖掘输入层中的更多信息,完成更复杂的信息处理。其隐含层中的神经元还可以捕捉数据中的非线性关系,适用于非线性的电磁兼容数据。并且其相邻层之间的神经元可以进行信息传递,而每一层中的纵向神经元间则无信息交互,因此,BP 神经网络可挖掘电磁兼容数据的更多信息,完成更复杂的信息处理。其具有的反向传输方法,不断地对网络的参数进行微调,预测值逐渐逼近真实值,具有很强的模式识别和数据拟合能力。




图 2 BP 神经网络结构图

Fig. 2 Structure diagram of BP neural network

对于电磁兼容故障诊断,文献[15]首次尝试了将数据挖掘和特征分析相结合,对电磁兼容测试数据特征进行分析研究。该方法探究了数据挖掘对电磁兼容测试数据的应用可能性,通过模糊聚类方法实现搭接点性能优异的判断,并提出使用 BP 神经网络对历史数据进行训练,进而实现测试参数规律的预测,但数据样本过少,存在误差。文献[16]基于现场测试数据,提出了电磁兼容模型综合的概念。该方法研究了神经网络方法对电磁兼容数据挖掘的可行性,实现对电子元器件老化、各组件所用材料变质、电子设备结构变形等状态的故障预测来指导电磁兼容诊断和设备维护。文献[17]提出了基于改进灰狼优化(IGWO)算法的 BP 神经网络模型的电磁兼容故障诊断方法。该方法首先将故障树分析方法得到的故障最小割集中的原因向量作为特征输入,使用 IGWO 算法优化 BP 神经网络诊断模型,其诊断流程如图 3 所示。文献[18]提出基于小波包和 BP 神经网络的电磁兼容故障诊断方法。该方法是对设备出现故障的情况下检测得到的电磁兼容测试数据使用小波变换进行去噪,并使用小波包、峰值、包络 3 种方法

进行特征提取,通过 BP 神经网络实现电磁兼容故障诊断,基于此构建电磁兼容数据分析处理系统。表 2 为 BP 神经网络用于电磁兼容故障诊断。




图 3 故障诊断模型
Fig. 3 Fault diagnosis model

表 2 BP 神经网络用于故障诊断

Table 2 Application of BP neural network in fault diagnosis

BP 神经网络	特点
文献[15-16]BP 神经网络	很好的泛化能力,具有较高的计算效率
文献[17]IGWO 算法和 BP 神经网络	改善了陷入局部极小,提高了网络的收敛速度
文献[18]LM 算法和 BP 神经网络	降低对调参的依赖性,较快的计算速度,占据了较小的存储空间

BP 神经网络可以自动学习提取电磁兼容的高维特征信息,学习捕捉信号中的突变频段,但是 BP 神经网络需要大量的电磁兼容数据才可以得到很好的效果,所以可以考虑使用数据增强的方法对数据进行扩增来保证电磁兼容故障诊断的能力。BP 神经网络相比于深度学习而言,网络结构简单,模型泛化能力不强,诊断结果依赖于设计的网络结构和合适的优化算法。

3.3 深度学习故障诊断方法

与传统机器学习故障诊断方法不同,深度学习学习方法其自身就具有强大的特征提取功能,通过构建深层网络,学习和分析大量数据中的模式和规律,来准确识别设备和运行状态之间复杂的映射关系,发现器件状态与电磁兼容数据之间的关联。典型 CNN 的基本结构主要由输入层、卷积层、

激活函数、池化层、全连接层和输出层组成,CNN 模型如图 4 所示。它是利用多层卷积操作和池化操作,这可以有效地捕捉电磁兼容故障数据中的局部特征。CNN 可以学习不同层级之间的特征,底层卷积层可以提取不同的低级特征,较高的卷积层可以提取更高层次的抽象特征,这种多层次的表示有助于对复杂的电磁兼容故障模式进行建模和识别。并在电磁兼容故障诊断中,CNN 的一个重要特点参数共享能够减少模型参数,更好地适应不同的故障样本,提高模型的鲁棒性。




图 4 CNN 结构图

Fig. 4 Structure diagram of CNN

将一维电磁兼容数据转为二维图像情况下进行处理,文献[19]提出使用双谱表示的深度残差神经网络,实现电磁干扰诊断。该方法将检测的电磁干扰信号通过高阶谱方法 HOS 进行双谱处理,并通过将时域信号射到双光谱图像作为模型输入,利用深度残差神经网络(ResNet)模型实现了设备状态监测。由于 CNN 结构的灵活性,可搭建多层卷积或者特征融合多通道卷积,同时学习不同表现形式下的电磁兼容数据的特征。文献[20]利用双谱分析和深度学习方法进行绝缘故障数据的特征提取和分类,搭建电磁干扰数据分类系统。该方法是先对电磁干扰信号进行实值和复值双谱特征处理,之后构建 ResNet 和 CNN 模型的单、双通道以及复杂的 6 组模型,并进行实验对比,最终得出同时利用双频谱实部和虚部会对模型性能所有提升,且具有双通道的 ResNet 实现故障诊断性能最佳。CNN 除了可用来处理二维数据,其变形 1D-CNN 用来处理一维数据,文献[21]提出使用基于迁移学习训练的 1D-CNN 卷积实现实时故障诊断。该方法将真实的电磁干扰原始分辨信号直接作为输入,并使用迁移学习方法训练 1D-CNN 模型,数据和模型二者结合开发了低成本高精度的端到端框架,用于对电磁干扰进行分类,诊断流程如图 5 所示。采用的 1D-CNN 和迁移学习方法具有更高的分类性能和计算效率。针对电磁兼容数据量不足的情况,深度学习方法也有着很好的解

决办法,使用由 CNN 作为生成器和判别器的架构生成对抗网络(GAN)对数据进行增强,通过反向传播算法,利用其在大规模数据集上强大的学习能力,自动学习数据的特征表示和分类边界。还可以与经典的小样本学习方法结合,例如:度量学习、原型网络等,来提高诊断精度,解决小样本情况下的电磁兼容故障问题。文献[22]使用了度量学习进行电磁兼容故障诊断的方法。该方法是由四重 CNN 组成作为嵌入模型,将输入样本转换为隐式特征空间,以及使用度量函数来量化采样点之间的相似度,来实现电磁兼容的故障诊断。




图 5 迁移学习和 1D-CNN 故障诊断

Fig. 5 Fault diagnosis of using transfer learning and 1D-CNN

基于 CNN 的电磁兼容故障诊断的目的就是使用一种自动化诊断方法,无需人工进行特征提取。该方法核心是 CNN 结构和参数的选择,不同选择可能带来不同的故障诊断效果。但搭建一个合适的网络并不容易,需要专业知识和时间,需要通过不断的迭代测试和修改搭建最合适的电磁兼容诊断模型。在实际应用中,能获取的电磁兼容数据有限,单一的使用 CNN 可能存在模型泛化能力差的问题,所以可与其他方法相结合共同实现电磁兼容故障诊断。表 3 为 CNN 用于电磁兼容故障诊断。

表 3 CNN 用于故障诊断

Table 3 The Application of CNN in fault diagnosis

卷积神经网络方法	特点
文献[19]ResNet 模型	减少测试误差并防止模型过度训练
文献[20]1D-CNN 模型和迁移学习	模型计算时间短,较低计算成本实现较高分类精度
文献[21]双通道 ResNet 模型	提高了类间和类内分类的性能
文献[22]度量学习	解决小样本问题,提高类别之间的差异性,提高分类准确性

4 总结和展望

随着人工智能的快速发展,基于机器学习的故障诊断方法已经成为热点的研究方向。本文介绍了机器学习中传统机器学习和深度学习的基本概念、模型结构以及模型优势,并对各方法的主要研究进行分析总结。传统的机器学习方法结构简单、易理解、易操作,在小样本情况下应用广泛,但对于处理复杂和大规模数据的能力有限。深度学习方法相比于传统机器学习方法,无需人工的干预,自主的学习特征隐藏规律,并且具有较强的拟合能力,但是实际应用中对于计算资源要求较高。从目前机器学习的发展状况来看,在基于电磁兼容故障诊断领域仍有如下几个方面需要研究:

(1)在实际工业情况下,电磁兼容的数据量存在采集数量有限、历史数据无保留、数据无故障标签等情况,导致电磁兼容数据规模不大。对于小样本情况下的机器学习,选择合适的传统机器学习模型可以处理大部分问题。但使用深度学习进行小样本处理存在过拟合、泛化能力差等问题,则可以通过数据增强、迁移学习、元学习等方式来应对深度学习情况下小样本问题,对于小样本情况下的基于机器学习的电磁兼容故障诊断仍然是未来研究的重要方向;

(2)在对器件的电磁兼容性研究中,选择正确的训练数据至关重要,模型是学习训练数据的参数空间,通常数据质量不佳,模型的诊断能力也会受到影响。实际电磁兼容数据中出现异常数据是无法避免的,这也是电磁兼容故障诊断面临的问题之一。为减少数据对诊断精度的影响,可以对数据进行初步的筛选,保留正确的数据样本,并减少样本之间维度的差异;还可以在数据层面对电磁兼容数据进行预处理,比如傅里叶变换、小波变换、时频分析等方法,提取信号中的重要信息,剔除其中的干扰信号,还可以改变数据表现形式。针对数据样本不均衡情况,使用欠采样、过采样等方法处理数据集,对于算法层面可以采用代价敏感、集成方法等方法进行处理;

(3)实际应用中,不同领域电磁兼容故障大不相同,数据具有各自的特点,需要选择合适的机器学习模型适应不同的故障诊断情况。基于数据驱动的机器学习具有良好的学习能力,其模型多种多样,每种模型具有各自的优缺点,使用机器学习模型去面对各种各样的数据特性。可以结合工程师经验和电磁兼容数据特点,将不同模型有效融合,充分利用各模型的优势,并同时使用先进算法

优化,实现不同情况下的电磁兼容故障诊断。如何构建高效的电磁兼容故障模型已经成为未来研究的一个重要方向;

(4)搭建在线监控平台是未来发展趋势,通过诊断模型建立对器件或者设备状态的实时监控,这有助于对电磁兼容故障发生进行预测或者快速诊断,以达到保证器件稳定性和延长器件寿命的目的。同时随着诊断数据的不断增加,数据规模也在不断壮大,充足的数据量有助于电磁兼容故障诊断性能的提升。建立一个实时更新的电磁兼容数据库,将检测数据在线保存,不断使用新数据去更新诊断模型,实现模型的进一步优化。

机器学习在电磁兼容故障诊断领域的应用改变了传统人工干预的诊断方式,缩短了诊断周期,提高了诊断的效率,进一步促进器件的电磁兼容性提升,保证了设备的安全稳定运行。尽管已经取得了一些积极的成果,但随着基于机器学习的发展,在电磁兼容故障诊断领域仍需更深入研究。

参考文献

- [1] 刘 磊.电子元器件试验与检测方法研究[J].工程管理与技术探讨,2023,5(19):236-238.
- [2] 吕 琛.故障诊断与预测[M].北京:北京航空航天大学出版社,2012.
- [3] Lei Y, Yang B, Jiang X, et al. Applications of Machine Learning to Machine Fault Diagnosis: A Review and Road Map[J]. Mechanical Systems and Signal Processing, 2020, 138: 106587.
- [4] 文成林, 吕菲亚.基于深度学习故障诊断方法综述[J].电子与信息学报, 2020, 42(1): 234-248.
- [5] 梁 喆.基于故障树分析车载系统电磁兼容诊断方法研究[D].西安:西安电子科技大学, 2013.
- [6] 郭小凯.车载系统电磁兼容故障诊断方法研究[D].西安:西安电子科技大学, 2012.
- [7] 杨晓伟.基于故障树和现场测试的 EMC 故障诊断方法[D].西安:西安电子科技大学, 2015.
- [8] 莫植铭.基于故障树的在线电磁兼容故障诊断技术[D].西安:西安电子科技大学, 2019.
- [9] 秦启森.基于故障树的电子设备电磁兼容故障分析[D].西安:西安电子科技大学, 2022.
- [10] Petrovski S, Bouchet F, Petrovski A. Data-driven Modelling of Electromagnetic Interferences in Motor Vehicles Using Intelligent System Approaches[A]. IEEE International Symposium on Innovations in Intelligent Systems & Applications[C]. 2013: 1-7.
- [11] Wu J, Cui S, Su D. Spectrum Data Feature Analysis Based on Support Vector Machine Method[A]. 2017 Sixth Asia-Pacific Conference on Antennas and Propagation[C]. 2017: 1-3.
- [12] Mohamed k, Abulifa S, Abulifa A. Artificial Intelligent Techniques for Identifying the Cause of Disturbances in the Power Grid[J]. Research of Artificial Intelligence, 2023, 3(1): 19-31.
- [13] Lei J, Mu J, Zeng L, et al. An Intelligent Vehicle Oriented EMC Reverse Diagnostic Model Based on SVM[J]. 2020 IEEE Intelligent Vehicles Symposium, 2020: 1544-1549.
- [14] Chen L, Chai Y, Zeng L, et al. An Intelligent Vehicle Oriented EMC Fault Shooting Method Based on Semi-supervised Learning[A]. IEEE International Conference on Net-work Intelligence and Digital Content[C]. 2021: 1-5.
- [15] 胡 晓.车载通信系统电磁兼容测试数据特征分析研究[D].西安电子科技大学, 2015.
- [16] 李高升, 林成龙, 迟名远, 等.基于现场测试数据的电磁兼容模型综合方法[J].微波学报, 2016, 32(2): 77-83.
- [17] 方 烜, 杨 帆, 梁家豪, 等.基于改进灰狼算法-BP神经网络的智能巡检机器人电磁兼容故障诊断[J].科学技术与工程, 2022, 22(1): 243-249.
- [18] 申 晨.基于小波变换的电磁兼容测试数据分析处理技[D].西安:西安电子科技大学, 2021.
- [19] Mitiche I, Jenkins M, Boreham P, et al. Deep Residual Neural Network for EMI Event Classification Using Bispectrum Representations[A]. 26th European Signal Processing Conference[C]. 2018: 186-190.
- [20] Mitiche I, Jenkins M, Boreham P, et al. An Expert System for EMI Data Classification Based on Complex Bispectrum Representation and Deep Learning Methods [J]. Expert Systems With Applications, 2021, 171: 114568.
- [21] Mitiche I, Nesbitt A, Conner S, et al. 1D-CNN Based Real-time Fault Detection System for Power Asset Diagnostics[J]. IET Gener Trans. Distrib, 14(24): 5766-5773.
- [22] Shen X, Zhou Z. Metric Learning-based Neural Network Model for Electromagnetic Compatibility Fault Diagnosis: An Application Study[A]. 2023 5th International Conference on Electronic Engineering and Informatics[C]. 2023: 542-545.